

Prova Final de Análise Estatística de Dados e Informações

(23/11/2025)

Nome: _____

Matrícula: _____

Questão 1 – (2,5 pontos)

Esta questão aborda a aplicação prática de um problema de Ciência de Dados utilizando **Regressão Linear**. O objetivo é prever preços de imóveis com base em dados reais da região de *King County*, nos Estados Unidos. A base de dados utilizada é a [Previsão de Vendas de Imóveis em King County \(EUA\)](#). Siga os passos abaixo para desenvolver sua solução:

Instruções:

1. Análise Descritiva dos Dados (20%)

- Realize uma análise inicial da base de dados.
- Inclua estatísticas descritivas (média, mediana, desvio padrão, etc.) e gráficos relevantes (distribuições, correlações, etc.).

2. Construção do Modelo de Regressão Linear (30%)

- Construa um modelo de Regressão Linear para prever os preços dos imóveis.
- Apresente os coeficientes do modelo, R^2 e outras métricas de avaliação.

3. Interpretação dos Resultados (10%)

- Explique os resultados obtidos pelo modelo, destacando o impacto de cada variável nas previsões e explicações do fenômeno.
- Verifique se os pressupostos da Regressão Linear (linearidade, homocedasticidade, normalidade dos resíduos, etc.) foram atendidos.

4. **Ajustes no Modelo** (30%)

- Identifique possíveis problemas nos pressupostos do modelo.
- Apresente soluções para corrigir esses problemas, como transformações de variáveis ou ajustes no modelo.
- Reavalie o desempenho do modelo ajustado.

5. **Tomada de Decisão** (10%)

- Com base no modelo final, explique como os resultados podem ser aplicados em um contexto de negócios.
- Forneça exemplos de decisões estratégicas que poderiam ser tomadas com base nas previsões.

Questão 2 – (2,5 pontos)

Esta questão aborda a aplicação prática de um problema de Ciência de Dados utilizando **Machine Learning**. O objetivo é prever se os indivíduos irão cancelar suas reservas em uma rede de hotéis, utilizando o conjunto de dados [Hotel Booking Demand](#). Siga os passos abaixo para desenvolver sua solução:

Instruções:

a) **Análise Descritiva dos Dados** (10%)

- Realize uma análise descritiva da base de dados.
- Inclua gráficos e tabelas para explorar as características dos dados.

b) **Modelo de Regressão Logística** (60%)

- Construa um modelo de Regressão Logística para prever o cancelamento das reservas.
- Apresente as métricas de desempenho do modelo, como acurácia, precisão, recall e F1-score.

c) **Análise das *Features*** (20%)

- Identifique as *features* mais importantes para o cancelamento das reservas.
- Interprete os resultados, destacando quais variáveis têm maior impacto na previsão.

d) **Justificativa do Método** (10%)

- Explique por que a Regressão Logística é mais apropriada para este problema em comparação à Regressão Linear.

Questão 3 – (2,0 pontos)

Esta questão aborda a aplicação prática de um problema de **ANOVA (Análise de Variância)** utilizando dados reais empregados em contextos empresariais. O objetivo é analisar as médias de quantidades e preços de produtos agrupados por países, utilizando o conjunto de dados [Vendas de Varejo Online](#). Siga os passos abaixo para desenvolver sua solução:

Instruções:

a) **Análise Descritiva dos Dados** (10%)

- Realize uma análise inicial da base de dados.
- Inclua gráficos e tabelas que explorem as variáveis de interesse.

b) **Comparação entre Países (ANOVA)** (40%)

- Realize uma análise de variância (ANOVA) para comparar as médias de quantidade e preço dos produtos, agrupados por países.
- Apresente os resultados estatísticos, incluindo valores de F , p -valor e a interpretação dos mesmos.

c) **Ajustes no Modelo de ANOVA** (40%)

- Verifique os pressupostos da ANOVA (normalidade, homocedasticidade, etc.).
- Corrija possíveis problemas identificados e apresente um modelo ajustado.

d) **Interpretação e Tomada de Decisão** (10%)

- Interprete os resultados finais da análise.
- Destaque possíveis decisões estratégicas baseadas nos resultados encontrados.

Questão 4 – (3,0 pontos)

Você é analista de dados de uma instituição financeira. Sua missão é desenvolver um modelo preditivo para identificar clientes com maior probabilidade de se tornarem **maus pagadores** (inadimplentes). O banco quer usar essas informações para reduzir riscos, melhorar sua carteira de crédito e apoiar decisões estratégicas de concessão de empréstimos.

Será utilizada a base de dados [Risco de Crédito \(Kaggle\)](#), que contém informações sociodemográficas, comportamentais e financeiras dos clientes.

Variável-alvo: **Class** – *good* se o cliente é considerado *bom pagador*; *bad* se for *mau pagador*.

Instruções:

a) **Discussão sobre o problema** (10%)

- Contextualize o problema de risco de crédito no setor bancário e sua importância para a economia.
- Explique por que prever inadimplência é essencial para reduzir perdas e melhorar a gestão de crédito.

b) **Análise Descritiva dos Dados** (15%)

- Realize uma análise exploratória da base de dados.
- Apresente estatísticas descritivas e gráficos para compreender o comportamento das variáveis e sua relação com a variável **Class**.
- Faça tratamento de valores ausentes, padronização e codificação de variáveis, se necessário.

c) **Definição e Seleção dos Modelos** (30%)

- Escolha modelos de previsão adequados para o problema (ex: Regressão Logística, Árvore de Decisão, Random Forest, XGBoost, SVM).
- Justifique sua escolha com base nas características dos dados e no objetivo da análise.
- Compare os modelos utilizando métricas como acurácia, precisão, recall, F1-score e AUC.

d) **Explicabilidade das Variáveis – SHAP *value*** (25%)

- Utilize SHAP values no modelo final para identificar as variáveis mais relevantes para a previsão de inadimplência.
- Apresente gráficos interpretativos (ex: summary plot, force plot) e discuta o significado das variáveis mais influentes no contexto bancário e econômico.

e) Análise Não Supervisionada com K-Means e DBSCAN (15%)

- Aplique K-Means para segmentar os clientes com base em características como renda, idade, histórico de crédito, tempo de emprego etc.
- Justifique o número de clusters e interprete os perfis obtidos.
- Aplique DBSCAN para detectar perfis atípicos (outliers) que possam indicar risco elevado de inadimplência.
- Compare os resultados e discuta como os agrupamentos podem complementar a análise supervisionada.

f) Tomada de Decisão Estratégica (10%)

- Com base nos resultados obtidos, sugira ações que o banco poderia adotar para reduzir riscos futuros (ex: políticas de concessão, segmentação de clientes, ações de prevenção).
- Aponte como a análise de dados pode orientar estratégias de retenção, concessão responsável de crédito e prevenção de inadimplência.

Observação

Orientações para Entrega e Avaliação

- A prova é **individual** e deverá ser realizada dentro do prazo estipulado pela coordenação da disciplina. Trabalhos semelhantes, cópias ou plágios implicarão **atribuição de nota zero**, conforme regulamento institucional.
- O relatório final deverá ser entregue exclusivamente nos formatos **PDF** ou **HTML**, exportados diretamente do *Jupyter Notebook* ou *Google Colab*.
- Não serão aceitos:
 - Arquivos no formato `.ipynb`;
 - Capturas de tela ou trechos de código desconexos;
 - Relatórios sem fundamentação estatística ou interpretações coerentes.
- O relatório deverá conter obrigatoriamente:
 - Código-fonte comentado e executável;
 - Gráficos, tabelas e métricas relevantes para cada questão;
 - Descrição teórica dos modelos utilizados, com substituição dos dados reais conforme o problema;
 - Interpretações estatísticas e financeiras claras e alinhadas com os resultados obtidos.
- A não observância dos critérios metodológicos acima impedirá a justificativa dos resultados apresentados e comprometerá a atribuição do conceito correspondente.
- O prazo e o local de submissão da prova estão indicados na plataforma Moodle da disciplina.

Complemento Opcional

O discente poderá complementar o trabalho com uma interface interativa desenvolvida em **Streamlit** ou publicada via **Hugging Face Spaces**, permitindo simulações dinâmicas dos modelos e visualização interativa dos resultados. O link da aplicação poderá ser incluído ao final do relatório e será considerado **positivamente** na avaliação final.